

Especificação de Modelos para Análise Preditiva

(copyright/ISBN/ficha catalográfica)

Dedicatória (opcional)

Epígrafe (opcional)

Sumário

Introdução	1
1. Enquadramento do Problema Preditivo	2
1.1. Tipo de Aprendizado de Máquina	2
1.2. Regressão versus Classificação	3
1.3. Unidade de Análise	4
1.4. Métrica de Sucesso (RMSE, AUC, F1 etc.)	5
1.5. Restrições de Negócio	5
2. Baseline	8
2.1. Baseline para Regressão	8
2.1.1. Baseline Ingênua (Dummy Regressor)	8
2.1.2. Heurística Especialista	8
2.1.3. Baseline Estruturada	9
2.2. Baseline para Classificação	9
2.2.1. Baseline Ingênua (Dummy Classifier)	9
2.2.2. Heurística Especialista	9
2.2.3. Baseline Estruturada	10
3. Fatores de Decisão	11
3.1. Interpretabilidade	11
3.2. Capacidade de Capturar Não Linearidade	11
3.3. Custo Computacional	12
3.4. Hiperparâmetros	12
3.5. Sensibilidade aos Dados	12
4. Famílias de Algoritmos	15
4.1. Modelos Lineares	15
4.1.1. Interpretabilidade: alta	15
4.1.2. Não linearidade: baixa	15
4.1.3. Sensibilidade: outliers	15
4.1.4. Custo: baixo	15
4.1.5. Hiperparâmetros: baixo	15
4.1.6. Usar: baseline, relações simples	15
4.1.7. Evitar: padrões complexos	15
4.2. Modelos Baseados em Distância	15
4.2.1. Interpretabilidade: baixa	16
4.2.2. Não linearidade: média (local)	16
4.2.3. Sensibilidade: escala, dimensionalidade	16
4.2.4. Custo: baixo treino / alto inferência	16
4.2.5. Hiperparâmetros: médio (k)	16
4.2.6. Usar: padrões locais	16
4.2.7. Evitar: alta dimensão / latência	16
4.3. Modelos Baseados em Árvores	16
4.3.1. Interpretabilidade: média (alta se rasa)	16
4.3.2. Não linearidade: alta	16
4.3.3. Sensibilidade: menos a escala, sensível a ruído	16
4.3.4. Custo: médio	16
4.3.5. Hiperparâmetros: médio	16
4.3.6. Usar: relações complexas	16
4.3.7. Evitar: overfitting (árvores profundas)	16
4.4. Neurais (quando aplicável)	16
4.4.1. Interpretabilidade: muito baixa	17
4.4.2. Não linearidade: muito alta	17
4.4.3. Sensibilidade: dados e escala	17
4.4.4. Custo: alto	17
4.4.5. Hiperparâmetros: alto	17
4.4.6. Usar: grande volume / padrões complexos	17
4.4.7. Evitar: pouco dado / necessidade de explicação	17

5.	Natureza dos dados.....	18
5.1.	Tamanho (n amostras, p features).....	18
5.2.	Tipo (tabular, texto, temporal)	18
5.3.	Qualidade (missing, outliers, ruído)	18
5.4.	Relações esperadas (linear vs não linear)	18
6.	Critérios de seleção	19
6.1.	Interpretabilidade	19
6.2.	Complexidade vs overfitting	19
6.3.	Escalabilidade	19
6.4.	Sensibilidade a escala/outliers	19
6.5.	Performance esperada vs custo	19
7.	Estratégia prática (workflow)	20
7.1.	Começar simples (baseline → linear/logística)	20
7.2.	Testar árvore → ensemble.....	20
7.3.	Comparar métricas em validação.....	20
7.4.	Evitar pular direto para modelos complexos	20
8.	Validação.....	21
8.1.	Métrica alinhada ao negócio	21
8.2.	Comparação justa (mesmo split)	21
9.	Iteração	22
9.1.	Ajuste de hiperparâmetros	22
9.2.	Feature engineering	22
9.3.	Troca de modelo (se necessário)	22
10.	Armadilhas comuns	23
10.1.	Data leakage	23
10.2.	Overfitting.....	23
10.3.	Métrica errada	23
10.4.	Dataset desbalanceado ignorado	23
11.	Decisão final	24
11.1.	Melhor trade-off (não só métrica)	24
11.2.	Modelo utilizável em produção	24
11.3.	Estável e explicável quando necessário.....	24

Introdução

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Integer nec odio. Praesent libero. Sed cursus ante dapibus diam. Sed nisi. Nulla quis sem at nibh elementum imperdiet. Duis sagittis ipsum. Praesent mauris. Fusce nec tellus sed augue semper porta. Mauris massa. Vestibulum lacinia arcu eget nulla.

Class aptent taciti sociosqu ad litora torquent per conubia nostra, per inceptos himenaeos. Curabitur sodales ligula in libero. Sed dignissim lacinia nunc. Curabitur tortor. Pellentesque nibh. Aenean quam. In scelerisque sem at dolor. Maecenas mattis. Sed convallis tristique sem. Proin ut ligula vel nunc egestas porttitor.

Morbi lectus risus, iaculis vel, suscipit quis, luctus non, massa. Fusce ac turpis quis ligula lacinia aliquet. Mauris ipsum. Nulla metus metus, ullamcorper vel, tincidunt sed, euismod in, nibh. Quisque volutpat condimentum velit. Class aptent taciti sociosqu ad litora torquent per conubia nostra.

1. Enquadramento do Problema Preditivo

Antes de pensar em qualquer algoritmo, é imprescindível saber qual é o problema que se está tentando resolver. O problema preditivo possui características específicas, e estruturá-lo adequadamente desde o início aumenta significativamente as chances de sucesso.

1.1. Tipo de Aprendizado de Máquina

Em aprendizado de máquina, os problemas podem ser organizados em três grandes tipos: supervisionado, não supervisionado e, em menor escala, aprendizado por reforço.


No aprendizado **supervisionado**, o modelo aprende a partir de dados históricos onde o **resultado já é conhecido**. Ou seja, temos exemplos com entradas (X) e saídas (Y), e o objetivo é aprender a relação entre eles para fazer previsões em novos dados. Esse tipo de abordagem é utilizado em problemas de regressão (quando o resultado é numérico) e classificação (quando o resultado é categórico). No aprendizado **não supervisionado**, não existe uma variável-alvo definida. O objetivo é **explorar os dados e identificar padrões**, como agrupamentos (clustering) ou estruturas ocultas. Já o aprendizado **por reforço** envolve agentes que aprendem por tentativa e erro, interagindo com um ambiente para **maximizar uma recompensa** ao longo do tempo.

Em análise preditiva, temos um objetivo claro: **prever um resultado futuro**.

Para isso, usamos **dados históricos onde esse resultado já é conhecido**. Esse tipo de problema é chamado de **aprendizado supervisionado**, pois o modelo aprende a relação entre as informações de entrada (X) e o resultado (Y). Técnicas não supervisionadas também podem aparecer indiretamente, mas

ANÁLISE PREDITIVA: FOCO EM APRENDIZADO SUPERVISIONADO

Objetivo: prever um resultado futuro a partir de dados históricos.



RESUMO: O coração da análise preditiva é o aprendizado supervisionado, pois temos um alvo (Y) a prever. Técnicas não supervisionadas são ferramentas de apoio para entender, preparar e enriquecer os dados.

normalmente como apoio (por exemplo, para agrupar dados ou criar variáveis). O núcleo da previsão, porém, é supervisionado.

1.2. Regressão versus Classificação

Dentro do aprendizado supervisionado, os problemas se dividem principalmente em **regressão** e **classificação**.

Na **regressão**, o objetivo é **prever um valor numérico contínuo**, como receita, tempo ou quantidade, entre outros. Já na **classificação**, o objetivo é **prever uma categoria ou classe**, como “inadimplente ou não”, “churn ou não”, ou categoria de cliente (ouro, diamante, safira etc.), entre outros.

Em análise preditiva, os problemas costumam se enquadrar em uma dessas duas categorias porque sempre existe um resultado futuro bem definido a ser estimado, como vimos. Esse resultado, por natureza, será ou um valor numérico (quanto?) ou uma categoria (qual grupo?).

APRENDIZADO SUPERVISIONADO: REGRESSÃO X CLASSIFICAÇÃO


No **aprendizado supervisionado**, o modelo aprende a partir de dados históricos onde o resultado (variável-alvo) já é conhecido.

O objetivo é usar esse aprendizado para prever o resultado em novos casos.

DOIS TIPOS PRINCIPAIS DE PROBLEMAS PREDITIVOS

1. REGRESSÃO

Objetivo: prever um valor numérico contínuo.
Resposta para a pergunta: **QUANTO?**



Exemplos de variáveis-alvo


- Preço de um imóvel
- Tempo de entrega
- Quantidade vendida
- Receita prevista
- Temperatura

Características

- Resultado numérico contínuo
- Pode assumir qualquer valor dentro de um intervalo
- Ex.: 25, 25.3, 25.37, 26...

2. CLASSIFICAÇÃO

Objetivo: prever uma categoria ou classe.
Resposta para a pergunta: **QUAL GRUPO / CLASSE?**



Exemplos de variáveis-alvo

- Inadimplente (sim/não)
- Churn (sim/não)
- Fraude (sim/não)
- Tipo de cliente (A, B, C)
- Categoria de produto

Características

- Resultado é uma categoria ou classe (rótulo)
- Número finito de classes (binária ou multiclases)
- Ex.: sim/não, 0/1, A/B/C...

COMO IDENTIFICAR QUAL TIPO DE PROBLEMA?



Observe a variável-alvo (Y), ou seja, o que você deseja prever.



SE O RESULTADO FOR:

um número contínuo
(pode assumir muitos valores)

→ **É REGRESSÃO**

Ex.: 10.2, 35.6, 1.75, 100.0...

SE O RESULTADO FOR:

uma categoria ou rótulo
(número finito de classes)

→ **É CLASSIFICAÇÃO**

Ex.: sim/não, baixo/médio/alto, A/B/C...



RESUMO

Em análise preditiva, todo problema tem um resultado futuro que queremos estimar. Esse resultado será, por natureza, ou um **valor numérico (regressão)** ou uma **categoria (classificação)**.

Para identificar se o tipo de problema envolve regressão ou classificação, basta **observar a variável-alvo**. Se o resultado esperado for um número **contínuo**, trata-se de regressão. Se for uma **classe ou rótulo**, trata-se de classificação.

Por exemplo:

Exemplo 1 — Regressão

Uma empresa deseja prever o **faturamento** de cada cliente nos próximos 120 dias com base no histórico de compras, frequência e valor médio gasto.

Nesse caso, a **variável-alvo** é um valor numérico contínuo (faturamento). Logo, trata-se de um problema de regressão.

Exemplo 2 — Classificação

Uma empresa deseja prever se um cliente irá cancelar o serviço nos próximos 120 dias com base no seu comportamento recente na plataforma.

Nesse caso, a **variável-alvo** é uma categoria (cancelou ou não cancelou). Logo, trata-se de um problema de classificação.

1.3. Unidade de Análise

Ok. A seção anterior deixou claro o quanto é importante a definição da unidade de análise. Ela corresponde **à entidade do mundo real sobre a qual a previsão será realizada**. Em outras palavras, define “para quem” ou “para o quê” o modelo irá gerar uma resposta. Essa escolha determina a **granularidade do problema** e, como consequência, a estrutura do dataset, o tipo de variáveis utilizadas e a forma como os dados serão organizados.

A definição da unidade de análise não é apenas uma **decisão técnica**, mas principalmente uma **decisão de negócio**. Ela está diretamente relacionada à forma como o problema é formulado e ao tipo de decisão que se deseja apoiar. Para uma mesma situação, diferentes escolhas de unidade de análise podem levar a problemas preditivos distintos, cada um atendendo a objetivos específicos.

Por isso, a unidade de análise deve estar claramente alinhada ao objetivo da análise e à ação que será tomada a partir do modelo. Uma definição inadequada pode resultar em previsões corretas do ponto de vista técnico, mas sem utilidade prática, pois não respondem à pergunta certa ou não apoiam decisões relevantes.

Note ainda que a mesma base de dados pode ser reorganizada de diferentes formas, gerando problemas preditivos distintos a partir de unidades de análise diferentes. Por isso, essa decisão deve ser tomada antes da etapa de modelagem.

Por exemplo:

Exemplo 1 — Mesmo contexto, decisões diferentes (cliente vs transação)

Uma empresa deseja atuar na prevenção de fraudes.

Se a unidade de análise for o **cliente**, o modelo prevê a probabilidade de um cliente ser um potencial fraudador. O dataset será estruturado com uma linha por cliente, contendo variáveis agregadas como quantidade de transações, valores totais, valores médios, frequência, e outras variáveis indicativas de padrões de comportamento. A decisão de negócio envolve ações como monitoramento reforçado, restrições ou bloqueio preventivo da conta.

Por outro lado, se a unidade de análise for a **transação**, o modelo prevê se uma operação específica é fraudulenta. O dataset passa a ter uma linha por transação, com variáveis como valor da operação, horário, localização, tipo de dispositivo e comportamento recente. A decisão muda para aprovar OU rejeitar aquela transação em tempo real.

1.4. Métrica de Sucesso (RMSE, AUC, F1 etc.)

COMO A UNIDADE DE ANÁLISE MUDA O DATASET

A mesma base de dados pode ser reorganizada de diferentes formas, gerando problemas preditivos distintos.
A **unidade de análise** define a granularidade dos dados e, como consequência, o dataset, as variáveis e o tipo de modelo.

EXEMPLOS – CONTEXTO: FRAUDE

EXEMPLO 1

 **Unidade de análise: CLIENTE**

Objetivo: identificar se o cliente é um potencial fraudador.

Estrutura do dataset (exemplo)
Cada linha representa um cliente (dados agregados).

cliente_id	qtde_transacoes (ult. 90 dias)	valor_total_transacoes (ult. 90 dias)	qtde_dispositivos utilizados	% transacoes internacionais	atrasos_em. pagamento	target_fraude (potencial fraudador) (0 = não / 1 = sim)
1001	45	12.540,00	2	0,05	0	0
1002	132	48.300,00	5	0,32	1	1
1003	22	2.150,00	1	0,00	0	0
1004	87	15.780,00	3	0,12	0	0
1005	59	9.870,00	4	0,45	2	1
...	...	...	...	...	...	...

Decisão de negócio
Ações no nível do cliente:
monitoramento reforçado, revisão cadastral, limites, bloqueio preventivo etc.

EXEMPLO 2

 **Unidade de análise: TRANSAÇÃO / OPERAÇÃO**

Objetivo: identificar se uma operação específica é fraudulenta.

Estrutura do dataset (exemplo)
Cada linha representa uma transação/operação.

transacao_id	cliente_id	valor_transacao (R\$)	data_hora	canal	pais	dispositivo	tipo_operacao	target_fraude (transacao fraudulenta) (0 = não / 1 = sim)
9000001	1001	250,00	2024-05-01 10:15:23	app	BR	mobile_ios	transferencia	0
9000002	1001	4.850,00	2024-05-01 11:02:10	web	BR	desktop_win	compra	0
9000003	1002	1.299,00	2024-05-01 11:15:45	app	US	mobile_android	compra	1
9000004	1003	99,90	2024-05-01 11:20:11	app	BR	mobile_ios	pagamento	0
9000005	1002	7.500,00	2024-05-01 11:35:02	web	PY	desktop_win	transferencia	1
...	...	...	...	...	...	...	...	...

Decisão de negócio
Ações no nível da transação:
aprovar, recusar, solicitar autenticação adicional, revisão manual etc.

Conclusão
Mesma fonte de dados, unidades de análise diferentes → datasets diferentes → modelos diferentes → decisões diferentes.
Por isso, a escolha da unidade de análise deve vir antes da modelagem e estar alinhada ao **objetivo de negócio**.

A métrica de sucesso faz parte da definição inicial do problema porque ela estabelece, desde o início, o critério pelo qual o modelo será avaliado. Como diferentes métricas refletem diferentes objetivos de negócio (por exemplo, reduzir erros grandes, evitar falsos positivos ou não perder eventos raros), a escolha da métrica define o que significa “acertar” no contexto do problema. Sem essa definição, o problema fica incompleto, pois não há um critério claro para comparar modelos ou orientar a modelagem.

1.5. Restrições de Negócio


As restrições de negócio fazem parte do enquadramento inicial do problema porque delimitam quais soluções são viáveis na prática. Não basta obter um modelo com bom desempenho; ele precisa ser utilizável dentro do contexto operacional da organização.

Em muitos cenários, o **tempo de resposta** é uma restrição crítica. Aplicações como aprovação de transações ou detecção de fraude exigem decisões em tempo real, muitas vezes em milissegundos. Nesses casos, o modelo precisa ser simples e eficiente, priorizando velocidade de execução, mesmo que isso implique alguma perda de desempenho preditivo.

Em outros cenários, como previsão de demanda ou cálculo de LTV, as exigências de latência não são críticas, pois as decisões não precisam ser tomadas em tempo real. Por outro lado, esses problemas costumam envolver grande volume de dados e **maior necessidade de processamento**. Nesses casos, a solução pode ser executada em ambientes analíticos em nuvem, onde há maior capacidade computacional disponível. Isso permite o uso de modelos mais complexos e intensivos, com foco em maximizar a performance preditiva. Nesse contexto, a principal restrição deixa de ser o tempo de resposta e passa a ser o custo associado ao processamento e à infraestrutura (AWS, GCP etc.).

Interpretabilidade de Modelos de Machine Learning

A interpretabilidade está em um espectro: de modelos mais transparentes a modelos mais complexos.



Outra restrição relevante diz respeito à **interpretabilidade** do modelo. Em muitos contextos de negócio, além de prever com alta precisão, será necessário **entender e justificar a decisão tomada pelo modelo**. Isso é especialmente importante em áreas como crédito, saúde ou compliance, onde decisões precisam ser explicáveis para clientes, reguladores ou áreas internas. Nesses casos, modelos mais simples e transparentes, como **Regressão Linear**, **Regressão Logística** ou **Árvores de Decisão**, podem ser preferidos. Por outro lado, em cenários onde a

explicação não é crítica e o foco está exclusivamente na performance, pode-se optar por modelos mais complexos e menos interpretáveis, como *ensembles* (**Random Forest** e **Gradient Boosting**) ou **Redes Neurais**.

Ensemble

Ensemble é uma técnica que combina múltiplos modelos de aprendizado de máquina para produzir uma única previsão, geralmente com melhor desempenho do que modelos individuais.

2. Baseline

A definição de uma baseline segue o critério de adotar modelos com o menor nível de complexidade possível, para que, posteriormente, qualquer aumento de complexidade, acompanhado de maior capacidade de generalização, possa ser avaliado de forma sustentada. Ou seja, o ganho de desempenho precisa ir além do que foi estabelecido como padrão inicial. Sem uma baseline, não há **critério claro para avaliar o custo-benefício** de soluções mais complexas.

A baseline, portanto, estabelece uma referência mínima de desempenho que **qualquer modelo mais sofisticado deve superar**, funcionando como um critério de validação inicial para garantir que o processo de modelagem evolua de forma consistente e orientada a resultados.

2.1. Baseline para Regressão

2.1.1. Baseline Ingênua (Dummy Regressor)

A forma mais simples de baseline em regressão consiste em **prever sempre o valor médio da variável-alvo**. Nesse caso, o modelo **ignora completamente as variáveis explicativas** e assume que todos os casos terão o mesmo valor esperado. Apesar de simples, essa abordagem é importante porque estabelece um ponto de comparação mínimo: qualquer modelo útil deve superar esse desempenho.

Algumas métricas, inclusive, utilizam essa baseline como referência explícita. É o caso do **coeficiente de determinação (R^2)**, que mede o quanto o modelo melhora em relação à previsão baseada na média. Um R^2 igual a zero indica que o modelo não supera a baseline da média, enquanto valores negativos indicam desempenho pior do que essa baseline.

2.1.2. Heurística Especialista

Corresponde a atribuir regras baseadas no conhecimento empírico do domínio de negócio, ainda sem uso de qualquer algoritmo de aprendizagem. Em problemas de regressão, essas heurísticas geralmente assumem a forma de cálculos diretos ou aproximações.

Por exemplo, em um cenário de previsão de faturamento, pode-se estimar o valor futuro com base na média recente ajustada por um fator de crescimento esperado. Trata-se de uma abordagem mais inteligente do que uma abordagem ingênua, pois o cálculo, seja qual for, leva em consideração o conhecimento do negócio.

2.1.3. Baseline Estruturada

A baseline estruturada corresponde ao **primeiro modelo que utiliza as variáveis explicativas para realizar previsões**. Diferentemente da baseline ingênua, que ignora os dados de entrada, a baseline estruturada já **busca capturar padrões simples** presentes nos dados.

Assim, ela corresponde ao primeiro modelo que utiliza as variáveis explicativas para realizar previsões. Nesse contexto, a **Regressão Linear** se apresenta como a escolha natural, por representar o menor nível de complexidade capaz de capturar relações entre as variáveis, sem exigir parametrização relevante, mantendo simplicidade, interpretabilidade e baixo custo computacional.

Cabe ressaltar que, embora existam variações da própria regressão linear, como **Ridge e Lasso**, essas abordagens já introduzem maior nível de complexidade por meio de mecanismos de regularização. Além disso, algoritmos como **árvores** e métodos baseados em vizinhança (**KNN**), embora admitam formulações para regressão, geralmente são usados no contexto de classificação. Em ambos os casos, essas alternativas tendem a exigir parametrizações adicionais ou introduzir maior complexidade, não sendo, portanto, a primeira escolha de baseline estruturada, cujo objetivo é justamente estabelecer o **nível inicial mais simples de modelagem**.

2.2. Baseline para Classificação

2.2.1. Baseline Ingênua (Dummy Classifier)

A forma mais simples de baseline em problemas de classificação consiste em **prever sempre a classe majoritária**, isto é, a categoria mais frequente no conjunto de dados. Nesse caso, o modelo ignora completamente as variáveis explicativas e assume que todos os casos pertencem à mesma classe.

Apesar de simples, essa abordagem estabelece um ponto de comparação mínimo, especialmente em cenários com desbalanceamento de classes. Qualquer modelo útil deve ser capaz de superar esse desempenho, caso contrário, não há evidência de que esteja capturando padrões relevantes nos dados.

2.2.2. Heurística Especialista

Em problemas de classificação, essas heurísticas especialistas assumem a forma de decisões diretas que buscam separar classes com base em critérios conhecidos.

Por exemplo, no contexto de detecção de fraude, uma regra como “marcar como suspeita transações realizadas fora do padrão habitual do cliente” já pode estabelecer um patamar inicial de desempenho. Trata-se

de uma abordagem mais informada do que a baseline ingênua, pois incorpora conhecimento do domínio na tomada de decisão.

2.2.3. Baseline Estruturada

No contexto de problemas de classificação, a **Regressão Logística** se apresenta como a escolha natural, por representar o menor nível de complexidade capaz de modelar probabilidades associadas às classes, mantendo simplicidade, interpretabilidade e baixo custo computacional. Além disso, fornece uma saída probabilística que permite ajustar decisões conforme diferentes critérios de negócio.

3. Fatores de Decisão

Diversos fatores podem influenciar a escolha de um modelo, como disponibilidade de dados, restrições de negócio, familiaridade do analista com as técnicas, facilidade de implementação e contexto de aplicação, entre outros. Os critérios apresentados a seguir concentram os principais aspectos técnicos utilizados na prática. Eles servem como base para orientar a comparação entre diferentes abordagens e apoiar a tomada de decisão ao longo da modelagem.

3.1. Interpretabilidade

A interpretabilidade diz respeito à facilidade de **entender como o modelo toma decisões**. Em muitos contextos de negócio, não basta prever corretamente; é necessário explicar o porquê da previsão. Modelos mais interpretáveis permitem identificar relações entre variáveis e justificar decisões, sendo especialmente importantes em cenários regulatórios ou sensíveis, como concessão de crédito, diagnósticos em saúde, detecção de fraude ou decisões jurídicas.

3.2. Capacidade de Capturar Não Linearidade

A capacidade de capturar não linearidade refere-se à habilidade do modelo de representar **relações mais complexas entre as variáveis**. Em modelos lineares, assume-se que o efeito de cada variável sobre o resultado é **proporcional e constante**, ou seja, **uma mesma variação em uma variável gera sempre o mesmo impacto na saída**. Esse comportamento pode ser crescente ou decrescente, mas não muda ao longo do domínio.

Em muitos problemas reais, no entanto, essa suposição não é suficiente. É comum que o efeito de uma variável dependa do seu próprio nível ou da interação com outras variáveis, caracterizando relações não lineares. Nesses casos, modelos mais flexíveis são necessários para capturar esses padrões.

Por exemplo, considere uma empresa hipotética em que cada ano adicional de experiência aumenta o salário do funcionário em R\$ 1.000. Nesse caso, esse efeito será sempre o mesmo, independentemente de a pessoa ter 1 ou 10 anos de experiência, caracterizando um comportamento simples e proporcional.

Agora considere outra empresa hipotética em que o impacto da experiência não é constante. O aumento salarial pode ser maior nos primeiros anos e diminuir ao longo do tempo. Além disso, o salário pode depender de fatores como área em que atua na empresa, disponibilidade de mão de obra para a mesma função, retorno que o profissional gera para a empresa, tempo na organização e a quantidade de pessoas sob sua gestão. Pode, inclusive, depender de fatores macroeconômicos que influenciam a concessão de bônus ou incentivos. Nesse caso, o efeito deixa de ser proporcional, caracterizando uma relação não linear.

De forma geral, modelos lineares tendem a ser mais simples, estáveis e interpretáveis, enquanto modelos capazes de capturar não linearidade introduzem maior complexidade, porém com potencial de melhor desempenho em cenários mais complexos.

3.3. Custo Computacional

O custo computacional está relacionado aos recursos necessários para **treinar e executar o modelo**, como tempo de processamento, uso de memória e infraestrutura disponível. Esse critério se torna especialmente relevante em cenários com **grande volume de dados** ou quando há necessidade de **resposta em tempo real**.

Por exemplo, em um ambiente analítico, onde o modelo pode ser executado em batch e com apoio de infraestrutura em nuvem, é possível utilizar modelos mais complexos e computacionalmente intensivos. Por outro lado, em sistemas que exigem baixa latência, como aprovação de transações, o modelo precisa gerar respostas rapidamente, o que favorece abordagens mais simples e eficientes.

Assim, o custo computacional influencia diretamente a escolha do modelo, pois limita quais abordagens são viáveis dentro do contexto operacional do problema.

3.4. Hiperparâmetros

Os hiperparâmetros são configurações do modelo definidas **antes do treinamento** e que controlam seu comportamento. Diferentemente dos parâmetros aprendidos a partir dos dados, os hiperparâmetros precisam ser **escolhidos pelo analista**.

Modelos com poucos hiperparâmetros tendem a ser mais simples, estáveis e fáceis de utilizar, pois exigem pouco ajuste. Por outro lado, modelos com muitos hiperparâmetros oferecem maior flexibilidade, mas demandam um processo de **tuning** mais cuidadoso, aumentando o tempo de desenvolvimento e a **dependência do analista**.


Assim, a quantidade e a sensibilidade dos hiperparâmetros influenciam diretamente a escolha do modelo, especialmente em cenários onde há limitação de **tempo, recursos ou experiência técnica disponível**.

3.5. Sensibilidade aos Dados

A sensibilidade aos dados diz respeito ao quanto o desempenho do modelo é afetado por características do conjunto de dados. Embora todos os modelos sejam impactados por essas características, cada um reage de forma diferente, o que torna esse aspecto um critério relevante na escolha do modelo.

FATORES DE DECISÃO

Critérios técnicos que orientam a escolha da família de algoritmos mais adequada para cada problema.



Entre os principais fatores de sensibilidade, destacam-se:

Escala das variáveis: modelos **baseados em distância** são altamente sensíveis, exigindo normalização; já modelos **baseados em árvores** são pouco sensíveis à escala.

Outliers: modelos **lineares** tendem a ser mais impactados por valores extremos, pois estes podem distorcer os coeficientes; modelos **baseados em árvores** tendem a ser mais robustos.

Dimensionalidade: modelos **baseados em distância** sofrem com o aumento do número de variáveis (curse of dimensionality), pois dependem de medidas de proximidade que perdem significado em alta dimensão e exigem comparação com muitas observações na predição. Modelos **lineares** e **baseados em árvores** tendem a lidar melhor com esse cenário.

Colinearidade: afeta principalmente modelos **lineares**, pois dificulta separar o efeito individual de variáveis muito correlacionadas, tornando os coeficientes instáveis e menos interpretáveis.

Valores faltantes (missing): muitos modelos, especialmente **lineares** e **baseados em distância**, exigem tratamento prévio, enquanto modelos **baseados em árvores** tendem a lidar melhor com esse tipo de situação.

Distribuição: distribuições muito assimétricas ou com caudas longas dificultam o ajuste de **modelos lineares**, enquanto modelos baseados em árvores e redes neurais tendem a lidar melhor com esse tipo de variação.

Ruído: modelos baseados em **distância** são mais sensíveis a ruído, enquanto modelos mais estruturados, como **árvores e redes neurais**, podem ser mais robustos, dependendo da configuração.