

Nome: - _____ / - _____
- _____ / - _____

Data:
21/05/26

Caso 1 — Recomendação de uso do KNN

Uma pequena clínica médica deseja desenvolver um sistema preditivo para auxiliar na identificação precoce de pacientes com risco de diabetes. O objetivo é utilizar dados históricos dos pacientes para apoiar triagens preventivas e reduzir atrasos diagnósticos. A clínica possui aproximadamente 2 mil registros históricos contendo atributos como idade, IMC, nível de glicose, pressão arterial, histórico familiar, consumo de álcool e tabagismo.

Durante as discussões iniciais, um analista sugeriu o uso do algoritmo KNN. Segundo ele, o modelo seria adequado por trabalhar bem com poucos atributos, utilizar lógica baseada em similaridade e não exigir treinamento complexo. Além disso, a clínica informou que deseja inicialmente uma solução simples de implementar, embora exista preocupação futura com crescimento da base de dados e interpretabilidade do modelo.

Com base no contexto apresentado, responda:

- a. Qual é a variável-alvo do problema? _____
- b. Qual é a unidade de análise? _____
- c. O problema é de classificação ou regressão? _____
- d. Como esse cenário poderia ser transformado em um problema de regressão/classificação?

- e. O uso do KNN parece adequado nesse contexto? Justifique considerando características do problema preditivo e do algoritmo.

Caso 2 — Evolução de Árvores de Decisão para Florestas Aleatórias (RF)

Uma instituição financeira deseja desenvolver um sistema preditivo para identificar clientes com maior risco de inadimplência. O objetivo é utilizar informações históricas dos clientes para apoiar decisões de concessão de crédito. O dataset atual possui aproximadamente 200 mil registros contendo atributos como renda mensal, idade, tempo de emprego, quantidade de empréstimos anteriores, histórico de atrasos, score de crédito e percentual de comprometimento de renda.

Inicialmente, a equipe optou por utilizar uma árvore de decisão isolada, pois o modelo produzia regras simples e facilmente interpretáveis pelos analistas de crédito. Entretanto, durante os testes, a equipe percebeu que pequenas alterações nos dados de treino geravam árvores bastante diferentes e que o modelo apresentava sinais de overfitting.

Diante desse cenário, outro analista sugeriu substituir a árvore isolada por um Random Forest. Segundo ele, a combinação de múltiplas árvores treinadas em diferentes amostras bootstrap poderia reduzir variância, aumentar estabilidade e melhorar a capacidade de generalização do sistema preditivo.

Com base no contexto apresentado, responda:

a. Qual é a variável-alvo do problema? _____

b. Qual é a unidade de análise? _____

c. O problema é de classificação ou regressão? _____

d. Como esse cenário poderia ser transformado em um problema de regressão/classificação?

e. Qual trade-off ocorre ao substituir uma árvore isolada por um Random Forest?

Caso 3 — Evolução de Florestas Aleatórias para Gradient Boosting (GBT)

Uma fintech desenvolveu inicialmente um modelo preditivo baseado em Random Forest para detectar fraudes em transações realizadas por cartões de crédito. O sistema passou a apresentar desempenho satisfatório em testes iniciais, especialmente por conseguir reduzir overfitting em relação a árvores isoladas. Entretanto, durante as avaliações mais recentes, a equipe percebeu que muitos padrões sutis de fraude ainda não estavam sendo capturados adequadamente, principalmente em transações raras e comportamentos mais complexos.

O dataset atual possui aproximadamente 2 milhões de transações contendo atributos como valor da compra, horário, localização geográfica, frequência recente de transações, tipo de dispositivo, padrão histórico do cliente e distância entre compras sucessivas.

Diante desse cenário, um dos cientistas de dados sugeriu substituir o Random Forest por um modelo baseado em Gradient Boosting. Segundo ele, o boosting poderia melhorar a capacidade preditiva do sistema ao construir árvores sequencialmente, onde cada nova árvore tentaria corrigir os erros cometidos pelas anteriores. Outro membro da equipe alertou que esse tipo de modelo pode aumentar significativamente o custo computacional de treinamento e exigir maior cuidado com overfitting e ajuste de hiperparâmetros.

Com base no contexto apresentado, responda:

- a. Qual é a variável-alvo do problema? _____
- b. Qual é a unidade de análise? _____
- c. O problema é de classificação ou regressão? _____
- d. Como esse cenário poderia ser transformado em um problema de regressão/classificação?

- e. Por que o Gradient Boosting pode melhorar o desempenho preditivo nesse cenário?

Caso 4 — Escolha entre modelos lineares e Redes Neurais

Uma empresa de streaming deseja desenvolver um sistema preditivo para estimar quais usuários possuem maior probabilidade de abandonar a plataforma nos próximos meses. O objetivo do projeto é permitir ações preventivas de retenção antes do cancelamento efetivo da assinatura.

O dataset disponível possui aproximadamente 3 milhões de registros históricos contendo atributos como tempo médio diário de uso, quantidade de filmes assistidos, horário predominante de acesso, frequência de pausas, buscas realizadas, tempo sem acessar a plataforma, avaliações dadas pelo usuário e padrão de consumo recente de conteúdo.

Durante os testes iniciais, a equipe utilizou modelos lineares tradicionais, porém percebeu que muitos padrões comportamentais aparentemente relevantes não estavam sendo bem capturados. Os cientistas de dados levantaram a hipótese de que o comportamento dos usuários envolve relações complexas entre variáveis, incluindo interações não lineares difíceis de representar explicitamente.

Diante disso, uma parte da equipe sugeriu o uso de uma MLP (Multi Layer Perceptron). Segundo eles, redes neurais poderiam aprender representações mais complexas dos padrões de comportamento dos usuários. Entretanto, outros membros destacaram preocupações relacionadas à interpretabilidade do modelo, custo computacional de treinamento e dificuldade de ajuste de hiperparâmetros.

Com base no contexto apresentado, responda:

- a. Qual é a variável-alvo do problema? _____
- b. Qual é a unidade de análise? _____
- c. O problema é de classificação ou regressão? _____
- d. Como esse cenário poderia ser transformado em um problema de regressão/classificação?

- e. Por que uma MLP pode ser adequada para esse problema preditivo?
