Questionário (ref. Aulas 01 a 04)

Capítulo I – O que é análise de dados

1) O que análise de dados?

Etapa de exame sistemático de valores observados com o objetivo de extrair informação relevante.

2) O que é análise descritiva?

Resume e organiza dados históricos para mostrar o que aconteceu, permitindo a geração de métricas, indicadores e dashboards.

3) O que é análise diagnóstica?

Busca explicar por que aconteceu, analisando causas, relações e fatores associados.

4) O que é análise preditiva?

Utiliza padrões dos dados históricos para estimar o que vai acontecer, via modelos estatísticos e ML.

5) O que é análise prescritiva?

Recomenda o que deve ser feito, considerando previsões, restrições e objetivos organizacionais.

6) O que é EDA (Análise Exploratória de Dados)?

Não é um tipo de análise por si só. Trata-se de uma abordagem transversal usada para investigar dados (padrões, distribuições, outliers, relações) em qualquer tipo de análise (descritiva, diagnóstica, preditiva ou prescritiva).

7) Porque a análise preditiva é mais "famosa" atualmente?

A análise preditiva ganhou destaque por utilizar ML/IA para antecipar eventos, tornando-se diferencial competitivo. Enquanto as análises descritivas e diagnósticas já existiam e estavam consolidadas antes mesmo do uso de IA (DW, Data Mart, mineração de dados), a análise preditiva representa o estágio atual de evolução das organizações, que ainda estão incorporando ML/IA (etapa necessária a viabilização da análise prescritiva). Ou seja, a análise preditiva é o "estado da arte".

Capítulo II – Processo de análise de dados

1) Historicamente, o processo de análise de dados foi estruturado em etapas que organizam o trabalho desde o entendimento até a interpretação dos resultados. Cite exemplos de modelos/metodologias.

KDD Process (Knowledge Discovery in Databases): processo de descoberta de conhecimento em bases de dados que envolve seleção dos dados, pré-processamento, transformação, mineração de dados e

interpretação/avaliação dos resultados. CRISP-DM (Cross Industry Standard Process for Data Mining): metodologia de mineração de dados com seis etapas principais: entendimento do negócio, entendimento dos dados, preparação dos dados, modelagem, avaliação e implantação. SEMMA (Sample, Explore, Modify, Model, Assess): metodologia usada em mineração de dados criada pelo SAS (originalmente significava Statistical Analysis System) que inclui amostragem dos dados, exploração inicial, modificação/preparação, construção de modelos e avaliação do desempenho dos modelos.

2) No curso adotamos um ciclo de vida para projetos de análise de dados composto por seis macroetapas. Quais são essas etapas?

No curso adotamos as etapas: entender, preparar, processar, analisar, compartilhar e implementar.

3) Qual é o objetivo da etapa Entender em análise de dados?

Definir o problema analítico e as perguntas que serão respondidas com os dados. Em análise preditiva, por exemplo, definir se o objetivo é prever churn, inadimplência, demanda ou LTV.

4) Qual é o objetivo da etapa Preparar em análise de dados?

Identificar e viabilizar as fontes de dados. Verificar se os dados existem, onde estão armazenados, como acessá-los, questões de governança, privacidade e autorização de uso. Em análise preditiva, envolve definir quais dados históricos (janela de observação) serão usados e "quanto futuro" se pretende prever (horizonte de observação).

5) Qual é o objetivo da etapa Processar em análise de dados?

Realizar limpeza e preparação técnica dos dados para garantir qualidade e consistência. Envolve tratamento de valores ausentes, correção de inconsistências, padronização de formatos, remoção de duplicidades e validações estruturais. Em análise preditiva, essa etapa assegura que os dados estejam confiáveis para uso posterior, sem ainda aplicar lógica de modelagem, ou seja, transformações que independem do modelo.

6) Qual é o objetivo da etapa Analisar em análise de dados?

Aplicar métodos analíticos e construir modelos para extrair padrões ou realizar previsões a partir dos dados. É nessa etapa que técnicas de machine learning são efetivamente utilizadas. Em análise preditiva, envolve a construção de atributos, a codificação de variáveis categóricas, transformações matemáticas, escalonamento, seleção e redução de atributos, além da escolha de algoritmos, treinamento, validação e teste, produzindo previsões e métricas de desempenho.

7) Qual é o objetivo da etapa Compartilhar em análise de dados?

Comunicar os resultados da análise de forma clara para apoiar interpretação e tomada de decisão. Essa etapa normalmente envolve a integração com ferramentas de visualização e comunicação de dados, como Tableau ou Microsoft Power BI. Em análise preditiva, inclui apresentar métricas (acurácia, AUC, erro), limitações do modelo e implicações práticas.

8) Qual é o objetivo da etapa Implementar em análise de dados?

Aplicar os resultados da análise em um contexto real de uso. Essa integração pode ocorrer de diferentes formas, como a geração pontual de resultados a partir do modelo, execuções periódicas em processos automatizados (lotes) ou integração direta em sistemas que realizam inferência em tempo real. Em análise preditiva, envolve colocar o modelo em produção, seja por execuções em lote, integração em sistemas ou inferência em tempo real, além de monitorar desempenho e efeitos das decisões ao longo do tempo.

Capítulo III – Formulação do problema preditivo

1) Por que problemas de análise preditiva normalmente são formulados como problemas de aprendizado supervisionado?

Porque existe uma variável-alvo explícita a ser estimada a partir de dados históricos. Embora existam exceções, a maioria dos problemas preditivos se enquadra em aprendizado supervisionado, pois o modelo aprende a mapear entradas (variáveis explicativas) para um resultado conhecido.

2) Quais são os tipos de tarefa/problema que surgem nesse contexto?

O aprendizado supervisionado divide a análise preditiva em problemas de regressão (valor contínuo) e problemas de classificação (classe/categoria).

3) O que são perguntas analíticas?

São questões formuladas de forma clara, mensurável e orientada a dados, que permitem serem operacionalizadas em variáveis, métricas ou modelos. Elas estruturam o problema analítico e definem elementos como unidade de análise, variável-alvo e horizonte temporal.

4) Escreva 2 exemplos de perguntas analíticas:
    a. Descritivas

    – Qual foi a receita mensal no último ano?

    – Qual foi nossa taxa de cancelamento mensal ano passado?

    b. Diagnósticas

– Que fatores explicam a queda da receita no último trimestre?
– Quais fatores estão associados ao aumento de churn?

c. Preditivas

– Quais clientes têm maior probabilidade de cancelar em 30 dias?
– Qual é o LTV de nossos clientes por nicho?

d. Prescritivas

– Que ações podem reduzir o churn em 30% no próximo ano?
– Quanto devo aumentar o preço para maximizar a receita?

5) O que é a unidade de análise?

É a entidade sobre a qual a previsão será feita e define a granularidade do problema. Determina como os dados serão organizados (linhas da base) e influencia todas as demais definições. Ex.: prever churn por cliente (uma linha por cliente, agregando suas transações) versus prever fraude por transação (uma linha por transação, com repetição do cliente quando houver múltiplas transações).

6) O que é variável-alvo?

É o resultado futuro associado à unidade de análise que o modelo tenta estimar. Deve ser mensurável e definido no tempo. Ex.: "inadimplente em 90 dias", "cancelou em 30 dias", "valor gasto no próximo mês".

7) O que é variável explicativa?

São as variáveis observáveis antes do evento que ajudam a prever o alvo. Devem estar disponíveis no momento da previsão. Ex.: renda, idade, histórico de compras, número de atrasos anteriores.

8) O que é horizonte de previsão?

Intervalo entre o momento em que a previsão é feita e o evento que se deseja estimar. Define "até quando" se quer prever. Ex.: prever churn em 30 dias, inadimplência em 90 dias.

9) O que é janela de observação?

Período do passado usado para construir as variáveis explicativas. Define "de onde vêm os dados". Ex.: usar últimos 6 meses de histórico para prever comportamento futuro.

10) A mudança da unidade de análise pode alterar a variável-alvo?

Sim. Porque o alvo está diretamente vinculado à unidade de análise. Ao mudar a unidade, muda também o que está sendo previsto. Ex.: se a unidade é cliente, a variável-alvo pode ser churn do cliente; se a unidade é transação, a variável-alvo passa a ser fraude da transação.

11) A mudança da unidade de análise pode alterar o conjunto de variáveis explicativas?

Sim. Pelo mesmo motivo: ao mudar a unidade de análise, muda a forma de construção das variáveis explicativas. Ex.: se a unidade é o cliente, as variáveis de várias transações precisam ser agregadas (média de gasto, total de compras); se a unidade é a transação, utilizam-se atributos diretos de cada transaão (valor da compra, forma de pagamento).

12) O que é vazamento de informação?

O vazamento de informação ocorre quando o modelo utiliza variáveis que não estariam disponíveis no momento real da previsão ou que incorporam, direta ou indiretamente, o próprio resultado a ser previsto, gerando desempenho artificial. Em problemas preditivos, o correto é utilizar apenas variáveis que existiam no instante da previsão. Isso acontece porque, ao trabalhar com dados históricos, algumas variáveis aparecem no dataset justamente porque foram registradas após o evento (e muitas vezes são usadas como rótulo), mas não podem ser usadas como explicativas. Por exemplo, ao prever se um cliente ficará inadimplente em 90 dias, utilizar uma variável como "valor pago após atraso" caracteriza.

13) O que é uma variável irrelevante?

É qualquer variável que não apresenta relação estatística significativa com a variável-alvo e, portanto, não contribui para reduzir sua incerteza. Seu uso tende a introduzir ruído, aumentar a complexidade do modelo e prejudicar a interpretabilidade, sem ganho preditivo. Ex.: identificadores como ID do cliente, códigos administrativos e chaves de relacionamento (primárias e estrangeiras), que servem para identificação/integração de dados, mas não explicam o fenômeno a ser previsto.

14) O que é uma variável redundante?

É uma variável que carrega essencialmente a mesma informação de outra já presente no conjunto de dados, sem acrescentar ganho preditivo relevante. Isso ocorre, em geral, quando há alta correlação ou dependência entre variáveis, fazendo com que ambas representem o mesmo fenômeno sob formas diferentes. O uso simultâneo aumenta a complexidade e pode dificultar a interpretação do modelo. Ex.: idade e ano de nascimento, ou renda mensal e renda anual.

15) O que é uma variável inviável (ou indisponível)?

É uma variável que até pode existir no dataset histórico, mas não estará disponível no momento em que o modelo for aplicado em produção. Isso ocorre quando a variável depende de coleta pontual, processo manual ou informação que não faz parte do fluxo operacional. Embora não seja vazamento de informação, seu uso torna o modelo impraticável, pois não

será possível reproduzir as mesmas entradas no uso real. Ex.: resultado de uma pesquisa específica que não é coletada continuamente.

16) O que é uma variável instável?

É uma variável cujo comportamento muda ao longo do tempo, fazendo com que os padrões aprendidos no passado deixem de representar adequadamente o futuro (drift). Essas mudanças podem ocorrer por alterações no contexto, como mercado, políticas ou comportamento dos usuários, reduzindo a capacidade de generalização do modelo. Parte dessas mudanças pode ser previsível e estruturada, como sazonalidade (ex.: aumento de compras na Black Friday), devendo ser incorporada ao modelo por meio de variáveis adequadas; outras são não antecipáveis (concept drift), exigindo monitoramento e re-treinamento. Assim, a instabilidade não é apenas um problema, mas uma característica inerente a muitos cenários reais, demandando atualização contínua dos modelos.

Capítulo IV – Engenharia de atributos

1) O que é engenharia de atributos?
2) O que é construção de atributos?
3) Explique esses tipos de construção de atributos:
    a. Combinações
    b. Agregações
    c. Discretização
4) O que é codificação de variáveis categóricas?
5) Explique esses tipos de codificações:
    a. Codificação One-Hot
    b. Codificação ordinal
6) O que são transformações matemáticas?
7) Explique esses tipos de transformações matemáticas:
    a. Transformação logarítmica
8) O que é escalonamento?
9) Explique esses tipos de escalonamento:
    a. Normalização
    b. Padronização
10) O que é seleção de atributos?
11) O que é redução de atributos?
12) Explique esses tipos de seleção e redução de atributos:
    a. Correlação
    b. Informação mútua

c. PCA